

陳宥霖

You-Lin Chen

大型語言模型 × 檢索增強生成 × 邊緣端部署

元智大學資訊工程碩士（在職進修）。專注於將 LLM、RAG 與參數高效微調（PEFT）落地到資源受限的邊緣環境，讓小模型在消費級 GPU 上達到甚至超越商用 API 的表現，能獨立完成資料工程、模型訓練、量化部署到系統整合的完整流程。

Email：annyjpc@gmail.com

領域：LLM / RAG / PEFT / NLP

線上完整作品集：附 index.html（含系統架構圖與 GitHub 連結）

代表性成果

自建小模型勝過商用 API

於 372 題測試領先 GPT-4o、Gemini 等 4 款商用 API +9.5~12.5 pts (p<0.001)

LLM 跑進 6 GB 消費級顯卡

DoRA 微調 + GGUF 量化，專家級 LLM 部署於 GTX 1060 邊緣環境

全國 AI 競賽 Top 20

AI CUP 2025 醫病語音個資辨識，擔任隊長帶領團隊參賽

7 項完整 AI / ML 專案

碩士研究、全國競賽到工程實作，涵蓋資料、訓練、部署全流程

技術能力

LLM / 生成式 AI

RAG · RAFT · DoRA / LoRA · SFT · Chain-of-Thought · GGUF 量化 · Prompt Engineering · 邊緣部署 · Agent Skills

框架與工具

PyTorch · Transformers · sentence-transformers · FAISS · ChromaDB · LiteLLM · LM Studio · WhisperX · Docker · pytest

機器學習 / NLP

BM25 / Hybrid 檢索 · Token Classification · 語音辨識 ASR · BERTScore 評估 · Wilcoxon 統計檢定 · Embedding · 實驗設計

使用過的模型

Qwen 0.5B-9B · whisper-large-v3 · BioLinkBERT-large · MiniLM · GPT-4o / Gemini（對照組）

程式與工程

Python · Git / GitHub · CLI 工具開發 · 乾淨架構 · 規格驅動開發 SDD · 單元測試 · IDEFO 功能建模

核心專案

★ 碩士論文

邊緣環境下水泥材料之檢索增強生成與微調策略研究

[論文全文 ↗](#)

獨立研究 · 元智大學資訊工程碩士論文 (86 頁) · LLM / RAG / PEFT / 邊緣部署

情境

為製造業技術傳承與人力斷層問題，打造可部署於邊緣端的水泥材料科學專家 LLM，縮短文獻回顧並提升決策效率。

行動

以 PyMuPDF 提取中英文文獻、Token 閾值雙路徑（單次 + Map-Reduce）摘要，自建 2,392 筆三段式 CoT QA；向量庫以 9 組受控實驗 + Wilcoxon 檢定選定最佳語料；Qwen 0.5B-9B 以 DoRA 微調並比較 SFT / RAFT，GGUF 量化部署於 GTX 1060 6GB。

成果

RAFT BERTScore 達 79.21；拒答率自 21.63% 大幅降至 1.01%；引用對齊率 85.81%；於 372 題測試領先 GPT-4o、Gemini 等 4 款商用 API +9.53~12.46 pts (p<0.001)。

RAFT

DoRA

FAISS

GGUF

Qwen

CoT

Wilcoxon

IDEFO

全國競賽

AI CUP 2025 醫病語音敏感個人資料辨識

[GitHub ↗](#)

隊長 (TEAM_7764) · 最終名次 Top 20 · ASR + NER 雙任務

情境

教育部主辦全國性 AI 競賽，需從醫病對話語音辨識並抽取敏感個資 (SHI)。

行動

Task1 以 whisper-large-v3 / Medical-Whisper 語音轉文字；Task2 以 BioLinkBERT-large 做 Token Classification，並用 o3 依標籤比例生成輔助資料強化長尾標籤。

成果

帶領團隊取得全國 Top 20 (Task1 Rank 30、Task2 Rank 14)。

WhisperX

BioLinkBERT

Token Classification

segeval

個人專案

Pi Memory — Coding Agent 跨 Session 記憶系統

[GitHub ↗](#)

LLM Agent • 資訊檢索 • Python

行動

實作 capture → store → retrieve → inject 記憶流程：BM25 檢索 + JSON 持久化 + **SHA-256 去重**，並額外實作 **BM25 + embedding 混合檢索** 克服詞彙不匹配。

成果

Token 預算內注入 context，讓 agent 跨對話記住關鍵觀察；附 benchmark 與**單元測試（全綠）**。

BM25

Hybrid Retrieval

sentence-transformers

pytest

期末專案

Hermes Agent 可驗證 Skill 套件

[GitHub ↗](#)

Agent Skills • 確定性自動評分

行動

打造多個可自動驗證的 Agent Skill：**Text2SQL**（NL+schema → 唯讀 SQL，結果 bag-equal）、**Code Author / Bug Hunter** 成對實作與稽核、**TestSmith** 僅憑規格生成殺死變異的測試。

成果

所有 Skill 輸出通過確定性評分（含 mutation-kill 率）。

Agent Skills

Text2SQL

Mutation Testing

SQLite

其他工程實作

水泥基材料科學個人知識 RAG 系統（Python）— 從 24 份開放授權文獻建構免 Docker 的 RAG 問答：ChromaDB + 多語 MiniLM Embedding、LiteLLM 統一呼叫層自動切換 Proxy／Gemini／OpenAI，回應附來源引用。[GitHub ↗](#)

LabData — **實驗數據整理 CLI 工具**（規格驅動開發）— 五模組乾淨架構；v2 純以「新增函式 + 可選參數」擴充比較／標籤／多工作表匯入，**零破壞既有 API**；零依賴 argparse 確保 CI 可運作。[GitHub ↗](#)

GreenPulse 提案計畫書與渲染管線（技術寫作）— 420 行 AI 平台提案並自建 Markdown → PDF 渲染管線（WeasyPrint + matplotlib mathtext + MathJax / Mermaid）。[GitHub ↗](#)

學歷與經歷

2024–2026

元智大學 • 資訊工程學系 碩士（在職進修）

論文《邊緣環境下水泥材料之檢索增強生成與微調策略研究》，指導教授 林明義博士。主攻 LLM、RAG、參數高效微調與邊緣端部署。

2025

AI CUP 2025 春季賽 • 隊長

醫病語音敏感個人資料辨識競賽，帶領團隊取得全國 Top 20。

在職期間

在職工程實務

於全職工作與碩士學業間並行推進研究，展現高度自律、時間管理與跨領域學習能力。